


FACULTAD DE CIENCIAS ECONÓMICAS Y ESTADÍSTICAS
UNIVERSIDAD NACIONAL DE ROSARIO

# Factores asociados a la baja de clientes en una empresa de telecomunicaciones

**Modelos Lineales Generalizados · Licenciatura en Estadística**
**Integrantes**: Shirli Kierzkowski , Pia Denipotti.
Octubre de 2026

## Introducción

La pérdida de clientes es uno de los problemas centrales en la industria de las telecomunicaciones. Captar un cliente nuevo suele ser considerablemente más costoso que retener a uno existente, por lo que anticipar qué clientes tienen mayor probabilidad de abandonar el servicio permite diseñar estrategias de retención más eficientes. En el presente trabajo se analiza la base *Telco Customer Churn*, que reúne información de clientes de una empresa de telecomunicaciones, incluyendo características del contrato, los servicios contratados y la condición de baja. Dado que la variable de interés es binaria (el cliente se da de baja o permanece), la regresión logística resulta el marco natural de análisis, ya que modela la probabilidad de baja y permite interpretar el efecto de cada variable explicativa.

## Objetivos

El objetivo general es modelar la probabilidad de baja de un cliente en función de su antigüedad, el tipo de contrato y el servicio de internet contratado. Los objetivos específicos son:

1. Ajustar un modelo lineal generalizado con respuesta binaria.
2. Evaluar la calidad del ajuste del modelo y su capacidad predictiva.
3. Interpretar los efectos de las variables mediante razones de odds y probabilidades estimadas.

## Material y métodos

Se utilizó la base *Telco Customer Churn* (Kaggle), con información de 7043 clientes. La variable respuesta es Churn, la cual indica si el cliente se dio de baja en el último mes (1 = sí, 0 = no). Por otro lado, las variables explicativas consideradas son:

- Antigüedad (*tenure*): cantidad de meses que el cliente permaneció en la empresa para quienes se dieron de baja, o bien, el tiempo transcurrido hasta el momento de la extracción de los datos para quienes continúan.
- Tipo de contrato (*Contract*): este puede ser “mes a mes”, “un año” o “dos años”.
- Servicio de internet (*InternetService*): este puede ser “DSL”, “fibra óptica” o “sin internet”.

Cabe mencionar que se excluyeron 11 clientes durante la etapa inicial del estudio. Los mismos contaban con antigüedad 0, es decir, estos no habían completado su primer mes[1]. Por consiguiente, el subsecuente análisis se realizó con 7032 clientes, de los cuales 1869 (26,6 %) se dieron de baja. Cada fila de la base corresponde a un cliente, por lo que se trata de datos no agrupados. El análisis se realizó en RStudio, con los paquetes pROC, ResourceSelection, caret y statmod.

[1] Además, en el modelo a presentar se utiliza el logaritmo de la antigüedad y la función no se encuentra definida para el valor 0

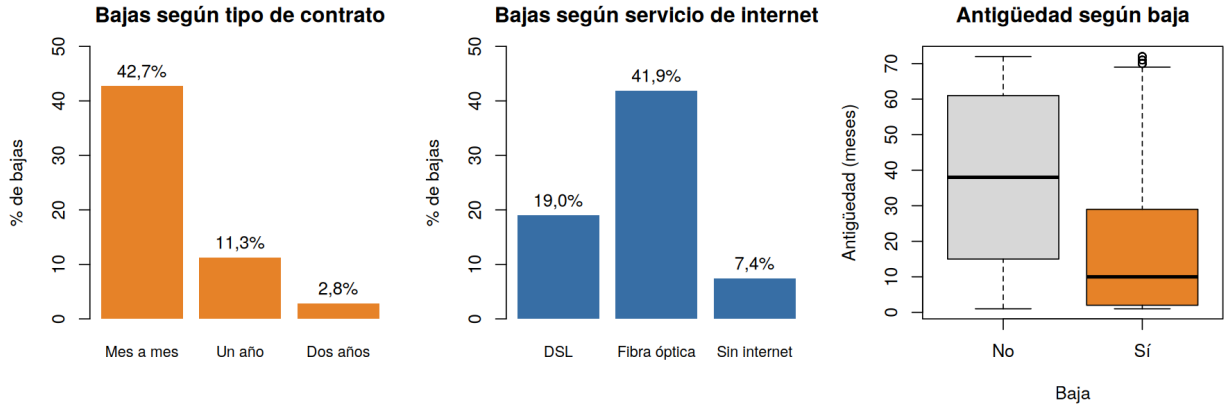
## Desarrollo

El análisis primario de los datos revela que la vasta proporción de clientes que cancelaron el servicio contaban con contratos temporales a corto plazo; más específicamente, el 88,6 % tenía contrato mes a mes, el 8,9 % contrato anual y el 2,6 % contrato bianual. En cuanto a tiempo en la empresa, los clientes que se dieron de baja tienen una antigüedad mediana de 10 meses, donde casi todos se concentran por debajo de los 30 meses (dos años y medio), frente a una mediana de 38 meses entre quienes permanecieron.
En cuanto al servicio de internet, la fibra óptica presenta la mayor tasa de baja (41,9 %), más del doble que el DSL (19,0 %), y los clientes sin internet registran la menor (7,4 %).

**Tabla 1.** Clientes y porcentaje de bajas según tipo de contrato y servicio de internet.

| Variable | Categoría | Clientes | % del total | % de bajas |
|---|---|---|---|---|
| Contrato | Mes a mes | 3875 | 55,1 | 42,7 |
| | Un año | 1472 | 20,9 | 11,3 |
| | Dos años | 1685 | 24,0 | 2,8 |
| Internet | DSL | 2416 | 34,4 | 19,0 |
| | Fibra óptica | 3096 | 44,0 | 41,9 |
| | Sin internet | 1520 | 21,6 | 7,4 |

**Figura 1**. Porcentaje de bajas según tipo de contrato y servicio de internet, y distribución de la antigüedad según baja.




Con el propósito de evaluar la relación entre la probabilidad de baja de un cliente y su antigüedad, el tipo de contrato y el servicio de internet contratado, se evaluaron distintos modelos de regresión logística, es decir, modelos lineales generalizados para respuesta binaria con enlace logit. Luego del análisis correspondiente[2] y bajo el principio de parsimonia se conservó el modelo que incluye los efectos principales de las tres variables, considerando Antigüedad en escala logarítmica.

$$logit\left(\pi_i\right) = \beta_0 + \beta_1 ln(Antigüedad_i) + \beta_2 UnAño_i + \beta_3 DosAños_i + \beta_4 Fibra_i + \beta_5 SinInternet_i$$

donde $\pi_i$ es la probabilidad de que el cliente i ($i=\overline{1, 7032}$) se dé de baja, y Anual, Bianual, Fibra y SinInternet son variables indicadoras para los tipos de contrato y de servicio de internet

[2] Ver Anexo A

(respectivamente), considerando como categorías de referencia el contrato mes a mes y el internet tipo DSL.

Este modelo permite estimar el efecto de cada variable explicativa sobre la probabilidad de baja, controlando por las restantes, y cuantificarlo mediante razones de odds. La Tabla 2 presenta las estimaciones de los parámetros y las razones de odds (RO) con intervalos de confianza del 95 % basados en el test de Wald. Puesto que la antigüedad se encuentra en escala logarítmica[1], exponenciar su coeficiente corresponde a la RO asociada a multiplicar la antigüedad por e ≈ 2,72. Consecuentemente, para una lectura más directa, se informa la RO por duplicación de la antigüedad[3] y se obtiene que la chance de que un usuario cancele del servicio de telefonía se reduce en un 32% al duplicar la antigüedad. Como el efecto es multiplicativo, es el mismo para cualquier punto de partida, es decir, el efecto de aumentar de uno a dos meses de antigüedad sobre la chance de cancelar el servicio es equivalente al efecto sobre esa misma chance al aumentar de 24 a 48 meses de antigüedad. De lo anterior se deduce que, en términos absolutos, un mes adicional pesa mucho más al principio de la relación con la empresa que al final, lo que sugiere que la retención de los clientes durante los primeros meses es fundamental.
Por otro lado, la chance de baja de un cliente que posee contrato anual es un 58 % menor que la de un cliente con contrato mes a mes, mientras que para los individuos con contrato de dos años dicha chance es un 86 % menor en comparación a los clientes con contrato tipo mensual. Finalmente, en cuanto al servicio de internet, la chance de cancelar el servicio de un cliente con fibra óptica es 3,49 veces la de un cliente con DSL. La de un cliente sin internet es un 69 % menor que la de un cliente con DSL.
Cabe mencionar que ningún intervalo de confianza incluye al 1, de modo que todos los efectos son significativos.

**Tabla 2.** Estimaciones de los parámetros y razones de odds

| Término | Estimación | Error estándar | RO | IC(RO) |
|---|---|---|---|---|
| Intercepto | $\widehat{\beta}_0 = 0,33$ | 0,080 | - | - |
| log(Antigüedad) (al duplicar la antigüedad) | $\widehat{\beta}_1 = -0,548$ | 0,029 | 0,68* | [0,66 ; 0,71] |
| Contrato de un año (vs. mes a mes) | $\widehat{\beta}_2 = -0,857$ | 0,100 | 0,42 | [0,35 ; 0,52] |
| Contrato de dos años (vs. mes a mes) | $\widehat{\beta}_3 = -1,941$ | 0,161 | 0,14 | [0,11 ; 0,20] |
| Fibra óptica (vs. DSL) | $\widehat{\beta}_4 = 1,249$ | 0,075 | 3,49 | [3,01 ; 4,03] |
| Sin internet (vs. DSL) | $\widehat{\beta}_5 = -1,164$ | 0,122 | 0,31 | [0,25 ; 0,40] |

* $exp\{\beta_1 ln(2)\} = 2^{\beta 1}$

La Tabla 3 exhibe la probabilidad estimada de baja para algunos perfiles de clientes, y la Figura 2 muestra cómo varía según la antigüedad y el tipo de contrato para los clientes con fibra óptica.

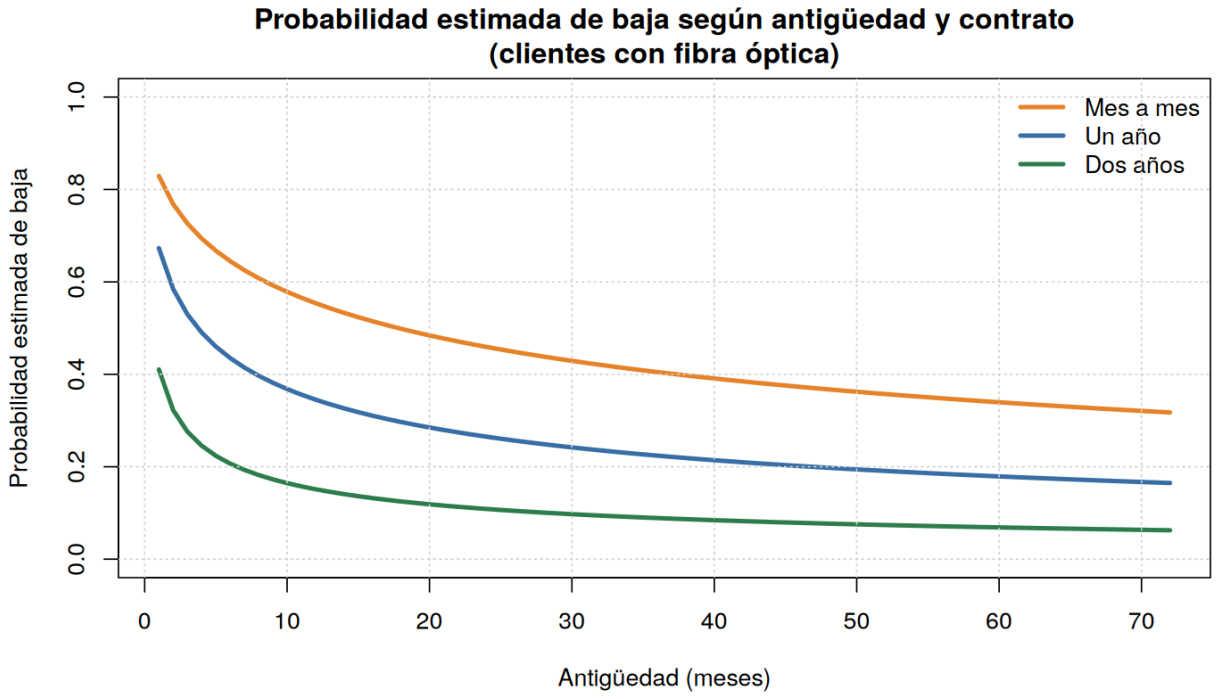
3

**Tabla 3.** Probabilidad estimada de baja para distintos perfiles de clientes.

| Antigüedad | Contrato | Internet | $\hat{\pi}$ |
|---|---|---|---|
| 1 mes | Mes a mes | Fibra óptica | 0,829 |
| 12 meses | Mes a mes | Fibra óptica | 0,554 |
| 60 meses | Mes a mes | Fibra óptica | 0,340 |
| 1 mes | Mes a mes | DSL | 0,582 |
| 1 mes | Un año | DSL | 0,371 |
| 1 mes | Un año | Sin Internet | 0,156 |

De los perfiles analizados, el perfil de mayor riesgo es el de un cliente nuevo, con contrato mes a mes y fibra óptica, con una probabilidad estimada de baja de 0,83. Para ese mismo perfil, la probabilidad estimada baja a 0,55 si el cliente lleva un año utilizando los servicios y a 0,34 si lleva cinco años. Se observa que modificar el servicio de internet (DSL en lugar de fibra óptica) para los clientes nuevos con contrato mensual también se asocia con una menor probabilidad estimada de cancelación de servicio, siendo esta 0,582. Por otro lado, los clientes nuevos con contrato anual e internet DSL tiene una probabilidad estimada de cancelar el servicio de 0,371 mientras que si no se le provee servicio de internet la probabilidad estimada resulta 0,156.
En la Figura 2 se observa que la probabilidad estimada de baja para clientes con fibra óptica (servicio de internet más elegido por los usuarios) decae rápidamente durante los primeros meses y posteriormente se estabiliza. Asimismo, las curvas de probabilidad estimada según los tres tipos de contrato quedan separadas para cualquier antigüedad, siendo mayor para los contratos mensuales y menor para los contratos bianuales.

**Figura 2**. Probabilidad estimada de baja según la antigüedad y el tipo de contrato, para clientes con fibra óptica.



Para evaluar la capacidad predictiva fuera de la muestra se realizó una validación cruzada de K = 10 particiones, estratificada para mantener en cada partición la proporción de bajas de la muestra. En cada partición, el modelo se ajustó con los K-1 grupos de entrenamiento, el punto de corte óptimo (máximo del índice de Youden) se eligió también con esos datos, y las medidas se calcularon sobre el grupo o fold de prueba.
Los cortes óptimos variaron entre 0,276 y 0,292 y el AUC entre 0,813 y 0,861, con promedios de 0,286 y 0,839 respectivamente (Tabla 4). Se observa, a su vez, que las medidas obtenidas con la muestra completa son notablemente similares a las de la validación cruzada, por lo que no hay evidencia de sobreestimación de la capacidad predictiva, algo esperable dado el reducido número de covariables en relación con el tamaño muestral.

**Tabla 4.** Medidas de capacidad predictiva en la validación cruzada (promedio de las 10 particiones) y en la muestra completa.

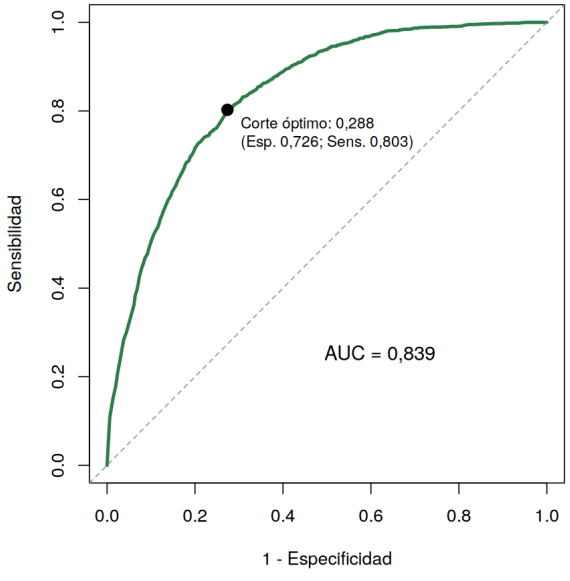
| | Punto de corte | AUC | Sensibilidad | Especificidad | Error global |
|---|---|---|---|---|---|
| Validación cruzada | 0,286 | 0,839 | 0,804 | 0,724 | 0,255 |
| Muestra completa | 0,288 | 0,839 | 0,803 | 0,726 | 0,253 |

**Tabla 5.** Tabla de clasificación con el punto de corte 0,288 en la muestra completa

| Observado \ Predicho | No baja | Baja | Total |
|---|---|---|---|
| No baja | 3750 | 1413 | 5163 |
| Baja | 369 | 1500 | 1869 |

Utilizando validación cruzada, el área bajo la curva ROC es 0,839 (Figura 3) lo que representa una buena capacidad predictiva del modelo. El índice de concordancia es también 0,839 lo que representa que en el 83,9 % de los pares formados por un cliente que se dio de baja y uno que no, el modelo asigna una probabilidad mayor al que se dio de baja. El punto de corte óptimo según el índice de Youden y la distancia euclídea al punto (0,1) es 0,286. Bajo el anterior umbral, el modelo detecta correctamente al 80,4 % de las bajas en promedio (sensibilidad) y clasifica correctamente al 72,4 % de los clientes que permanecen (especificidad), con un error global de 25,5 %

**Figura 3**. Curva ROC del modelo final, con el punto de corte óptimo según el índice de Youden.



## Conclusiones

En el presente trabajo se modeló la probabilidad de que un cliente de una empresa de telecomunicaciones se dé de baja mediante una regresión logística, en función de su antigüedad, el tipo de contrato y el servicio de internet contratado.

Los resultados muestran que las tres variables se asocian con la baja. La antigüedad tiene un efecto protector, en particular, al duplicarla reduce los odds de baja en un 32 % y, como el efecto es multiplicativo, un mes adicional pesa más al comienzo de la relación con la empresa que al final. Los contratos de mayor duración se asocian con una menor probabilidad de baja respecto del contrato mes a mes, y los clientes con fibra óptica presentan mayores probabilidades de baja que los de DSL y los que no contratan servicio de internet. De esta forma, los clientes nuevos, con contrato mes a mes y fibra óptica, concentran el mayor riesgo, mientras que los clientes antiguos con contratos de largo plazo presentan probabilidades muy bajas.

El modelo presenta un ajuste adecuado según el test de Hosmer-Lemeshow, el test de la función de enlace y el análisis de residuos, y no se detectaron observaciones influyentes. Su capacidad de discriminación es buena (AUC = 0,84) y se mantiene al evaluarla fuera de la muestra mediante validación cruzada. Con el punto de corte óptimo, el modelo identifica a 8 de cada 10 clientes que se dan de baja, pero clasifica incorrectamente a cerca de 3 de cada 10 de los que permanecen, de modo que resulta útil para priorizar acciones de retención sobre los clientes de mayor riesgo.

Finalmente, estos resultados sugieren que los esfuerzos de retención deberían focalizarse en clientes recientes con contratos mes a mes y, en particular, en quienes contratan fibra óptica.

# Anexo

## Anexo A. Selección y evaluación del modelo

**Tabla A1. Test de Razón de Verosimilitud**

| Modelo | Grados de libertad | -2Log(L) | Test R-V | ΔD | p-value |
|---|---|---|---|---|---|
| (Interacciones dobles) | 7018 | 6014,2 | - | - | - |
| (Antig*Contrato + Internet) | 7024 | 6024,6 | 1vs2 | 10,389 | 0,1092 |
| (Efectos principales) | 7026 | 6064,1 | 2vs3 | 39,491 | <0,0001 |

**Test de linealidad para Antigüedad en el Modelo 2**
$H_0$) Hay linealidad $H_1$) No hay linealidad

Estadística de prueba: 23,18
Grados de libertad: 9
P-value = 0,006

*En base a la evidencia muestral y con un nivel de significación del 5% se concluye que el efecto de la antigüedad no es lineal a través de los grupos. Se propone la transformación logarítmica para la variable y se evalúa la significación de los efectos y la bondad de ajuste del modelo resultante (Modelo 3).*

**Tabla A2. Tests de Razón de Verosimilitud para la significación de las variables en el Modelo 3**
La significación de cada variable se evaluó con el test de razón de verosimilitud, comparando el modelo completo con el modelo sin esa variable o efecto bajo la hipótesis nula: el efecto considerado no aporta significativamente en un modelo que posee las remanentes variables

| Efecto | ΔD | Δgl | p-value |
|---|---|---|---|
| log(Antigüedad) | 408.85 | 3 | < 0,001 |
| Contrato | 235.26 | 4 | < 0,001 |
| Servicio de Internet | 615.71 | 2 | < 0,001 |
| log(Antigüedad)*Contrato | 5.4562 | 2 | 0,07 |

Por consiguiente, con un nivel de significación del 5% se elimina el efecto interacción entre la antigüedad transformada y el tipo de contrato. Luego, se evalúa la significación del modelo final.

**Test de Hosmer y Lemeshow para bondad de ajuste del modelo final**
H0) El modelo ajusta bien H1) El modelo no ajusta bien

Estadística de prueba: 7,496
Grados de libertad: 8
P-value: 0,4842

*Con un nivel de significación del 5%, no existe evidencia muestral suficiente para concluir que el modelo no ajusta bien los datos, por ende, el modelo ajusta adecuadamente los datos.*

**Evaluación de la función de enlace**

Para evaluar la adecuación del enlace logit se ajustó un nuevo modelo que incluye como covariable al predictor lineal estimado (bajo el modelo final) al cuadrado de la forma: $logit\left(\pi_i\right) = \mathbf{X}_i\boldsymbol{\beta} + \gamma\hat{\eta}_i$

Haciendo uso del test de Wald, se evaluó la hipótesis $H_0$) $\gamma = 0$ la cual implica una correcta elección de la función de enlace. Con un nivel de significación del 5%, no existe evidencia muestral suficiente para concluir que $\gamma \neq 0$, es decir, que la elección del logit sea inadecuada ($\hat{\gamma} = 0{,}0016$, p-value=0,94) ergo se conserva la elección del enlace logit.

**Análisis de residuos**

Frente a las probabilidades estimadas y frente a la antigüedad, los residuos cuantiles se distribuyen alrededor de cero, sin tendencias ni cambios de variabilidad (Figura A1). Las franjas verticales se deben a que muchos clientes comparten el mismo perfil y, por lo tanto, la misma probabilidad estimada. En el gráfico QQ los residuos se adecuan bien a la recta identidad en el rango considerado (Figura A1). Por otro lado, solo el 0,3 % de los residuos queda fuera de la banda de ±3, la proporción esperable bajo normalidad.

La distancia de Cook máxima es 0,005 ($< 4/n = 0,00056$ el umbral usual), por lo que no se detectan observaciones influyentes.

**Figura A1**. Residuos cuantil frente a las probabilidades estimadas y a la antigüedad, y gráfico QQ normal.

