FACULTAD DE CIENCIAS ECONÓMICAS Y ESTADÍSTICAS

UNIVERSIDAD NACIONAL DE ROSARIO

Estudio de Factores Asociados a las Enfermedades Cardiovasculares

Cátedra: Análisis de Datos Multivariados

Carrera: Licenciatura en Estadística

Profesores: María Susana Vitelleschi y Sofía Suares

Alumnos: Pía Denipotti y Shirli Kierzkowski.

Año: 2025

Introducción

Las enfermedades cardiovasculares (ECV) representan una de las principales causas de mortalidad a nivel global, constituyendo un desafío persistente y significativo para los sistemas de salud pública. La detección temprana y la identificación precisa de los factores de riesgo son fundamentales no solo para mejorar el pronóstico de los pacientes, sino también para optimizar las estrategias de prevención primaria y secundaria.

El diagnóstico de estas patologías es un proceso inherentemente complejo. Rara vez depende de un único indicador patognomónico; por el contrario, requiere la evaluación conjunta y ponderada de múltiples dimensiones clínicas. Estas incluyen el historial clínico del paciente, mediciones fisiológicas (como la presión arterial, los índices de lípidos y la glucemia), variables antropométricas y los resultados de diversas pruebas diagnósticas, como electrocardiogramas o perfiles de biomarcadores.

Esta naturaleza multidimensional de los datos del paciente presenta un desafío analítico considerable. Las variables fisiológicas y clínicas no actúan de forma aislada; a menudo presentan altos grados de interdependencia y colinealidad. La evaluación de un factor de riesgo sin considerar su interacción simultánea con otros puede conducir a una comprensión incompleta o sesgada del perfil de riesgo del individuo.

Por lo tanto, se requieren enfoques que superen las limitaciones del análisis univariado tradicional. Las técnicas de análisis estadístico multivariado son herramientas metodológicas esenciales en este contexto. Estos métodos están diseñados específicamente para examinar las interrelaciones entre conjuntos de variables, permitiendo la identificación de patrones subyacentes, la reducción de la dimensionalidad de los datos y la cuantificación de las relaciones estructurales que definen el riesgo cardiovascular. El análisis multivariado proporciona así una gran herramienta para estudiar la compleja etiología de las ECV y caracterizar de manera más integral los perfiles de los pacientes.

Objetivo

Analizar los factores de riesgo asociados a las enfermedades cardíacas mediante la comparación de pacientes con y sin enfermedades cardiovasculares.

Objetivos Específicos

- Comparar pacientes cardiópatas y pacientes sanos con respecto a la presión arterial en reposo, el nivel de colesterol sérico, el número de vasos principales coloreados por fluoroscopía, la frecuencia cardíaca máxima alcanzada durante la prueba de esfuerzo y la depresión del segmento ST inducida por el ejercicio en relación con el reposo.
- Explorar y visualizar las relaciones de asociación entre el tipo de dolor de pecho, el grupo etario y el diagnóstico, para identificar perfiles de riesgo.
- Desarrollar una regla de clasificación que permita predecir la presencia o no de enfermedad cardiovascular basándose en el conjunto de variables predictoras y estimar el error de clasificación.

Material y métodos

Este trabajo utiliza la base de datos "Heart Disease Data Set"[1] del repositorio de la Universidad de California Irvine (UCI). La misma está compuesta por muestras recopiladas originalmente en 1989 por investigadores de cuatro instituciones de prestigio: el Instituto Húngaro de Cardiología (Budapest), el Hospital Universitario de Zúrich, el Hospital Universitario de Basilea, y el V.A. Medical Center en conjunto con la Cleveland Clinic Foundation.

---

[1] Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1989). Heart Disease [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C52P4X.

La base consolidada reúne 16 atributos de un total de 309 pacientes.

Variables:

- **Código identificador**: Identificador único del paciente (id).
- **Edad**: Edad del paciente en años (edad).
- **Origen**: Lugar del estudio o centro médico de origen (origen)
- **Sexo**: Sexo biológico del paciente (sexo).
- **Dolor de pecho**: Tipo de dolor de pecho reportado. Puede ser angina de pecho típica, angina de pecho atípica, dolor de pecho no anginoso y sin dolor de pecho (dolor_pecho)
- **Presión arterial**: Presión arterial en reposo en mm Hg (presion_art).
- **Colesterol**: Nivel de colesterol sérico en mg/dl (col).
- **Azúcar en sangre**: Variable indicadora sobre si el nivel de azúcar en sangre en ayunas es mayor a 120 mg/dl o no (azucar).
- **Electrocardiograma**: Resultado del electrocardiograma en reposo siendo este "normal", "anormalidad en segmento ST-T" o "hipertrofia VI" (electro).
- **Frecuencia cardíaca máxima**: Frecuencia cardíaca máxima alcanzada durante la prueba de esfuerzo en pulsaciones por minuto (frec_max).
- **Angina por ejercicio**: Angina inducida por el ejercicio con valores "Sí" o "No" (angina_ejer)
- **Depresión del segmento ST**: Depresión del segmento ST en el electrocardiograma inducida por el ejercicio en relación con el reposo (st_depre).
- **Pendiente del segmento ST**: La pendiente del segmento ST durante el ejercicio. Las categorías son plano, ascendente y descendente (st_pendiente).
- **Vasos coloreados**: Número de vasos principales coloreados por fluoroscopía con valores entre 0 y 3 (vasos).

- **Prueba de esfuerzo**: Resultado de la prueba de esfuerzo con Talio, el cual puede ser normal, defecto irreversible, defecto reversible (talio).
- **Desarrollo de la enfermedad**: grado de desarrollo de la enfermedad cardíaca del 0 al 4, siendo 0 la ausencia de enfermedad (etapa_enf).

A partir de ellas se crean las variables:

- **Grupo etario**: rango etario del paciente siendo las opciones “menor a 45”, “45-60” y “60 o más (grupo_edad).
- **Diagnóstico**: “Sin enfermedad” si el grado de desarrollo es 0, “Con enfermedad” si el grado de desarrollo es 1,2,3 ó 4 (Diagnóstico).

Resultados

Con el propósito de comparar de forma gráfica a los pacientes con y sin enfermedades cardiovasculares respecto a la presión arterial en reposo, el nivel de colesterol sérico, el número de vasos principales coloreados por fluoroscopía, la frecuencia cardíaca máxima alcanzada durante la prueba de esfuerzo y la depresión del segmento ST inducida por el ejercicio en relación con el reposo; se lleva a cabo, en primera instancia, un análisis de componentes principales (ACP) para reducir la dimensionalidad del conjunto de variables en un número menor de componentes no correlacionadas entre sí. En la mencionada técnica, se comienza definiendo la cantidad de componentes principales a retener en el estudio entre las p[2] posibles. Para esto, se considera la siguiente tabla:

Tabla 1: Autovalores de la matriz de correlación y proporción de variancia acumulada

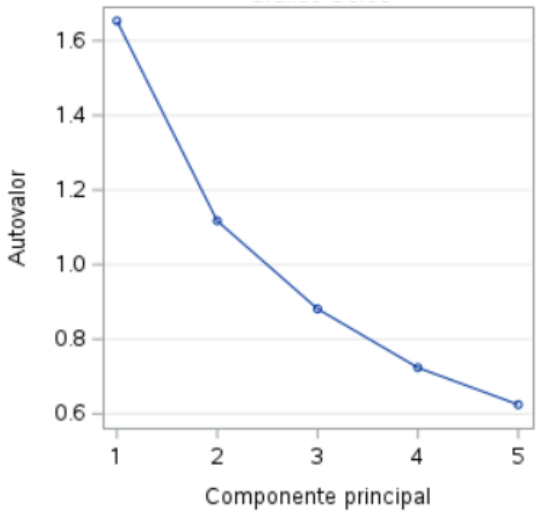
Autovalor	Proporción acumulada
1.653	0.3306
1.117	0.5541
0.881	0.7303
0.724	0.8751
0.625	1

En primer lugar, un criterio[3] es retener aquellas cuyos autovalores asociados sean mayores o iguales a 1, en este caso, únicamente la primera y segunda componente verifican esta condición (autovalores de 1.653 y 1.117 respectivamente). Asimismo, resulta necesario que los mismos expliquen un alto porcentaje de variancia acumulada (alrededor del 75% o más) por lo que se considera ingresar, a su vez, una tercera componente principal, incluso a pesar de estar asociado a un autovalor ligeramente menor a 1 (0.881). Por último, el gráfico de Scree (Figura 1) no

[2] p equivale a la cantidad de variables utilizadas en el análisis
[3] por haber sido los autovalores calculados a partir de la matriz de correlaciones

exhibe un “punto de quiebre” visiblemente reconocible, pero se detecta una leve constancia o estabilidad de los autovalores luego del tercero y se conserva la precedente decisión de conservar tres componentes.

Figura 1: Gráfico Scree



Luego, las componentes principales resultan:

$$y_1 = 0{,}31presion_art + 0{,}06col + 0{,}52\text{vasos} - 0{,}53frec_max + 0{,}59st_depre$$

$$y_2 = 0{,}52presion_art + 0{,}76col - 0{,}04\text{vasos} + 0{,}38frec_max + 0{,}01st_depre$$

$$y_3 = -0{,}73presion_art + 0{,}54col + 0{,}40\text{vasos} - 0{,}04frec_max - 0{,}06st_depre$$

No obstante, para una mejor interpretación de estas, se analiza la información proporcionada por la matriz de correlaciones de Pearson (Tabla 2).

Tabla 2: Correlaciones entre las variables en estudio y las 3 primeras CP

Variable	CP1	CP2	CP3
Presión arterial	0.4	0.55	-0.69
Colesterol sérico	0.08	0.81	0.51
Vasos coloreados	0.67	-0.04	0.38
Frec. cardíaca máxima	-0.68	0.4	-0.04
Depresión del segmento ST	0.76	0.02	-0.06

En cuanto a la primera componente, las variables más correlacionadas con esta son el número de vasos principales coloreados por fluoroscopía y la depresión del segmento ST inducida por

el ejercicio en relación con el reposo de forma positiva y la frecuencia cardíaca máxima alcanzada durante la prueba de esfuerzo de forma negativa. Por lo tanto, tomará valores altos cuando *vasos* y *st_depre* sean elevados y *frec_max* sea bajo, y tomará valores bajos en el caso contrario; ergo se la denominará "respuesta patológica al esfuerzo". En el caso de la segunda componente principal, se observa que la misma está fuertemente correlacionada con el nivel de colesterol sérico de manera positiva, y correlacionada moderadamente y de forma positiva con la presión arterial en reposo; de modo que se la llamará "nivel de colesterol sérico" por ser aquella la variable más influyente. En el caso de la tercera y última componente considerada, se observa que se encuentra correlacionada negativamente con la presión arterial en reposo por lo que valores altos de la componente estará representando a un bajo valor de la presión arterial en reposo y, por ende, se la llamará "Índice de normotensión".

Una vez definidas las componentes, se procede realizar los gráficos de las unidades valorizadas en las componentes principales definidas precedentemente con la intención de poder observar en ellos similitudes y diferencias entre pacientes cardiópatas y sanos.

Figura 2: Pacientes valorizados en las dos primeras CP, según diagnóstico

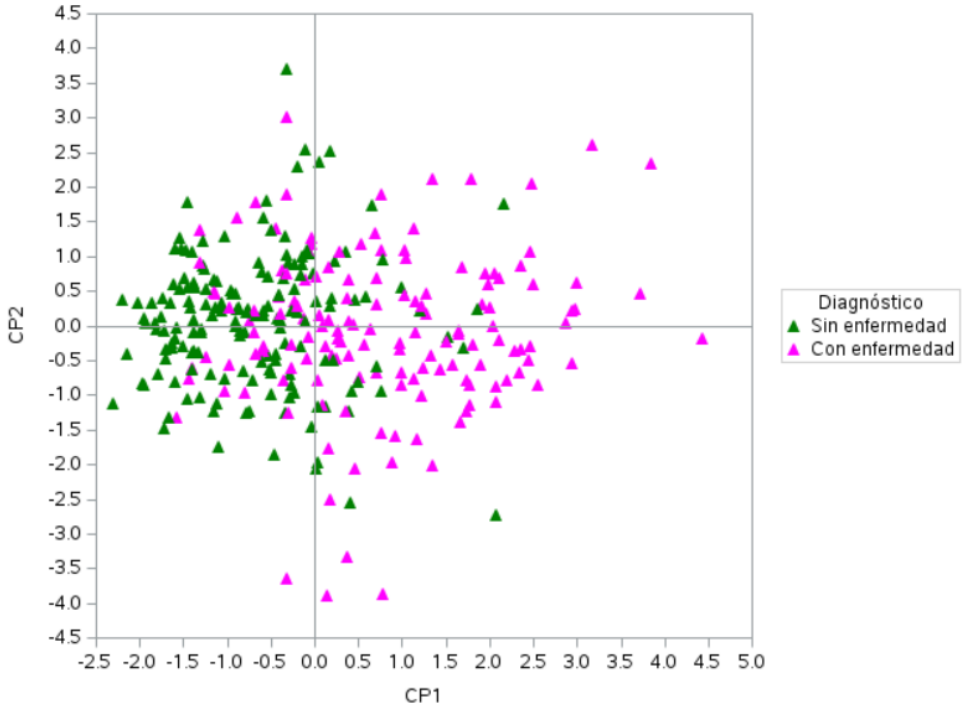
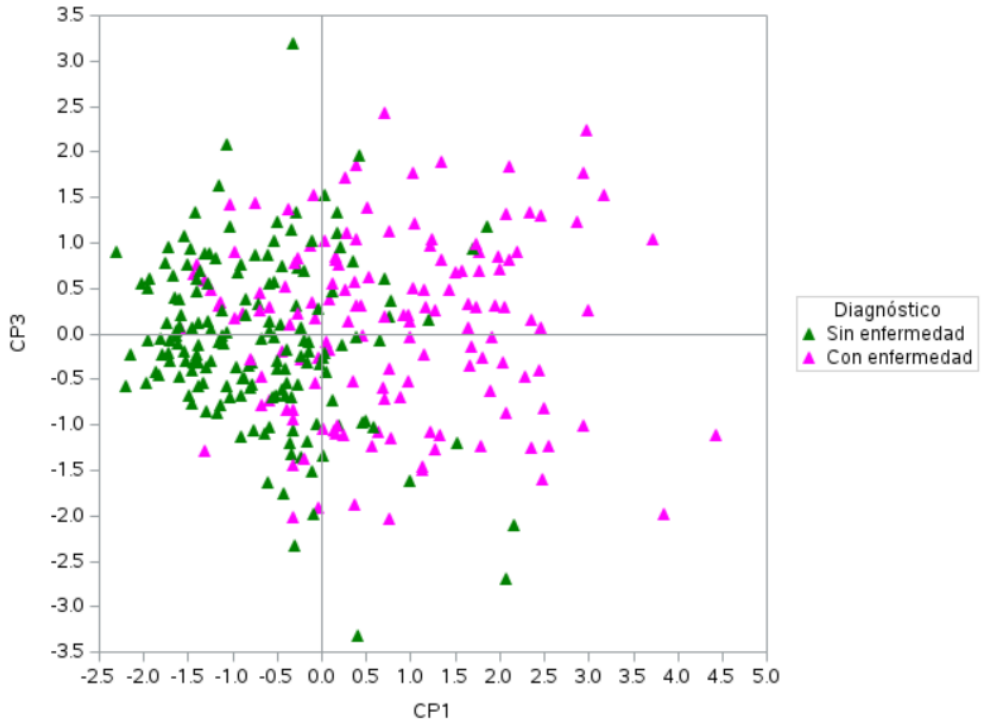


Figura 3: Pacientes valorizados en la primera y tercera CP, según diagnóstico



En las Figuras 2 y 3 se observa como las personas que padecen una enfermedad cardiovascular tienden a tener peores respuestas patológicas al esfuerzo que las personas sanas. Luego, con respecto al nivel de colesterol sérico (CP2) y la presión arterial en reposo o "Índice de normotensión" (CP3) no se detecta ninguna diferencia notoria entre las personas con ambos diagnósticos.

Se desea, a su vez, explorar y visualizar las relaciones de asociación entre el tipo de dolor de pecho, el grupo etario y el diagnóstico con el propósito de identificar perfiles de riesgo. Para ello, se utiliza el Análisis de Correspondencias Múltiples (ACM), que permitirá visualizar cómo se agrupan estas categorías según las frecuencias de aparición conjunta, y detectar perfiles específicos que complementen las conclusiones obtenidas anteriormente.

El criterio de selección de factores ha resultado en la conservación de las dos primeras dimensiones ya que, si bien la primera dimensión en sí misma explica el 97.12% de la inercia total, se decide retener a su vez a la segunda dimensión dado que utilizar ambas facilita la

interpretación del gráfico resultante. En conjunto, ambas dimensiones acumulan un 99.99%[4] de la inercia total explicada, permitiendo representar en un espacio bidimensional la estructura de las asociaciones sin casi perdida de información y asegurando que las conclusiones derivadas de la interpretación visual del gráfico sean fidedignas respecto a la estructura real de las asociaciones entre variables.

Debido a que la segunda dimensión se retuvo con fines ilustrativos y su aporte a la inercia total explicada es despreciable, su interpretación carece de sentido. Por el contrario, la interpretación de la primera dimensión se puede deducir a partir de la siguiente información:

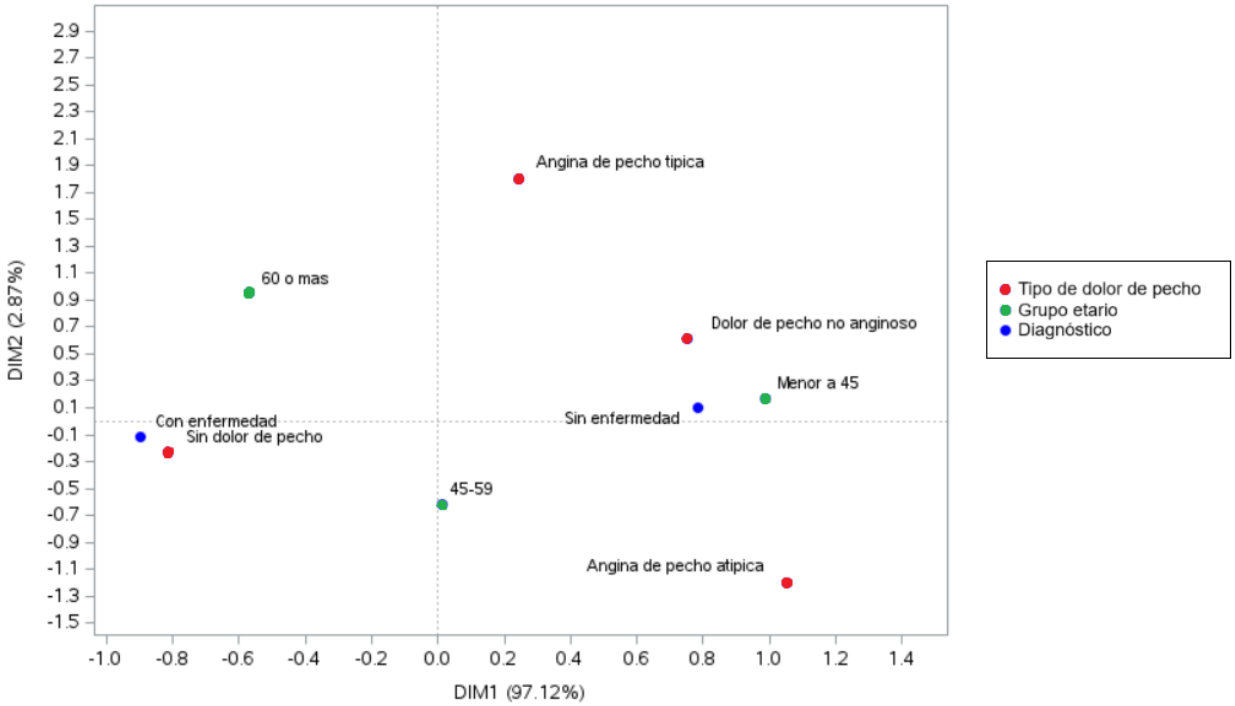
Tabla 3. Contribuciones absolutas de las categorías

Categoría	Dimensión 1
Con enfermedad	0.231
Sin enfermedad	0.202
Menor a 45	0.103
45-59	0
60 o más	0.061
Sin dolor de pecho	0.197
Dolor de pecho no anginoso	0.095
Angina de pecho típica	0.003
Angina de pecho atípica	0.109

Las variables que más contribuyen a la construcción de la primera dimensión son “Diagnóstico” explicando un 43.3% de la variabilidad total y “Tipo de dolor de pecho” con un 40.4%. Consecuentemente, y considerando la disposición de las categorías en la Figura 4, se define la mencionada dimensión como el “eje de salud vs enfermedad”.

[4] Ver Anexo

Figura 4. Mapa de categorías del Análisis de Correspondencias Múltiples



Se observa una alta frecuencia de aparición de pacientes con enfermedad, con isquemia silenciosa (o asintomática) y edades superiores a 60. Por el otro lado, también se identifica una alta frecuencia de aparición de pacientes sin enfermedad, con edades menores a 45 años y angina de pecho atípica o dolor torácico no anginoso. A partir de esto se deduce que la edad de los pacientes representa un factor de riesgo para las enfermedades cardiacas, particularmente en edades superiores a los 60 años, y, al contrario de la creencia común, las enfermedades suelen manifestarse sin dolor torácico.

Finalmente, resulta de interés desarrollar una regla de clasificación que permita predecir la presencia o no de enfermedad cardiovascular basándose en un subconjunto de variables predictoras cuantitativas (*st_depre*, *vasos* y *frec_max*) elegidas mediante el método de selección paso a paso. Para esto se llevará a cabo un análisis discriminante bajo el enfoque de clasificación de nuevos individuos en grupos previamente conocidos: “Con enfermedad” y “Sin enfermedad”.

Esta técnica requiere de una diferencia sustancial entre las medias de ambos grupos en cuanto a las mencionadas variables. Llevado a cabo el Análisis Multivariado de la Variancia

(MANOVA, por sus siglas en inglés), se concluye que el vector de medias para pacientes con enfermedad cardíaca difiere efectivamente del vector de medias para los pacientes sanos ($\Lambda = 0.65$, p-value < 0.0001); ergo la técnica es aplicable. Asimismo, con un nivel de significación del 5% se concluye a partir del test de homogeneidad de matrices de variancias y covariancias, que las mismas son diferentes entre ambos grupos ($\chi^2 = 73.19$, p-value < 0.0001). No obstante, dado que los tamaños muestrales son grandes y la cantidad de variables conservadas para el análisis menor a 6, estudios por simulación recomiendan el uso de funciones lineales discriminantes por sobre las cuadráticas[5].

La regla de clasificación resulta entonces:

$$W_{12}(\boldsymbol{x}) = 3.57 + 0.63st_depre + 1.06vasos - 0.03frec_max$$

$$Si\ W_{12}(\boldsymbol{x}) > 0 \Rightarrow \mathbf{x} \in \text{"Con enfermedad"}$$

$$Si\ W_{12}(\boldsymbol{x}) < 0 \Rightarrow \mathbf{x} \in \text{"Sin enfermedad"}$$

Bajo esta regla y el método de resubstitución o razón del error aparente para la estimación del error de clasificación se obtiene que la probabilidad de clasificar a un paciente con enfermedad cardiovascular como sano es del 29%, mientras que la probabilidad de clasificar como paciente cardiópata a un paciente sano es del 17%. De forma global, la probabilidad de clasificar erróneamente utilizando la regla anterior es del 23%.

Tabla 4. Resumen de validación cruzada usando la función discriminante lineal

Desde	Con enfermedad	Sin enfermedad	TOTAL
Con enfermedad	102 70.83%	42 29.17%	144
Sin enfermedad	28 16.97%	137 83.03%	165

[5] Ver Gilbert (1969) o Marks y Dunn (1974)

Conclusiones

A partir del análisis realizado, se identificaron patrones clínicos claramente asociados a la presencia de enfermedad cardiovascular. Los pacientes que presentan valores elevados de depresión del segmento ST inducida por el ejercicio, junto con un mayor número de vasos coronarios afectados, exhiben perfiles marcadamente más compatibles con enfermedad, especialmente cuando además alcanzan menores frecuencias cardíacas durante la prueba de esfuerzo. Por otro lado, el colesterol y la presión arterial en reposo no mostraron diferencias tan pronunciadas entre los grupos analizados.

En cuanto a las personas mayores de 60 años, estas constituyen el grupo con mayor frecuencia de enfermedad y, en muchos casos, esta se manifiesta sin dolor torácico, predominando perfiles asintomáticos. En contraste, los pacientes más jóvenes con dolor torácico no anginoso o angina atípica suelen aparecer con mayor frecuencia dentro del grupo sin enfermedad.

Finalmente, al evaluar la capacidad predictiva del conjunto de variables seleccionado, se obtuvo una regla que permite distinguir entre individuos con y sin enfermedad cardiovascular con un nivel de precisión del 77%. Si bien existe cierta probabilidad de clasificar erróneamente a algunos pacientes, los resultados globales muestran que la combinación de información clínica y funcional considerada ofrece un buen desempeño para identificar perfiles de riesgo.

Anexo

Tabla 5. Tabla de inercias ajustadas según propuso Benzécri (1979)

	Autovalores transformados	Porcentaje	Porcentaje acumulado
	0.04463	97.12	97.12
	0.00132	2.87	99.99
	$7.511*10^{-9}$	0.01	100.00
Total	0.04595	100.00	